

MOVIE RECOMMENDATION SYSTEM

Big Data & Machine Learning Souleymane Soumahoro

PROBLÉMATIQUE

"Comment aider un utilisateur à trouver des films parmi 25M+ possibilités ?"

Motivation personnelle :
Observation sur YouTube/Facebook
Curiosité →
Découverte du Big Data & ML
→ Construction de mon propre système

DONNÉES

(MovieLens small)

- 100 836 notes
- 9 742 films
- 610 utilisateurs
- Matrice 610 × 9724 (sparse 1,7%)

ARCHITECTURE

ETAPE 1 : Données CSV
ETAPE 2 : ETL (Pandas / Spark)
ETAPE 3 : Stockage MySQL
ETAPE 4 : API FastAPI

↓

MODELES ML

KNN → 93.4% Hit Rate
SVD → 0.746 RMSE
Content-based → 1.0 Cosine sim
Hybride → 0.97 NDCG

↓

DASHBOARD

Streamlit (4 pages)

MODÈLES ML

KNN (Collaboratif) → Hit Rate@10 : 93,4%
SVD (Factorisation) → RMSE : 0,746
Content-based (Genres) → Cosine sim : 1,0
Hybride (KNN+Content) → NDCG@10 : 0,97

QUALITÉ & TESTS

- 41/41 tests passants (100%)
- 0 valeur manquante, 0 doublon
- 100% notes valides (0,5–5,0)
- CI/CD : GitHub Actions (vert)

OPTIMISATIONS

- Cache Redis : -90% temps réponse
- Indexation MySQL : userId, movieId
- Partitionnement : 4 fichiers par décennie
- Compression modèles : -22%